BMODD 규칙분류 재현 안내서

한국 상장기업 사업보고서의 문장분류와 후속 경영효율 분석

기준일 2026 년 10 월 23 일 | 현재 잠금 입력판 25,041,971 개 문장

이 안내서는 고정된 사업보고서 원문에서 BMODD 와 NonBMODD 를 다시 집계하고, 동봉한 재무·시장자료와 결합하여 논문의 보존된 회귀모형을 실행하는 절차를 설명한다. 처음 사용하는 연구자도 원본 소스의 경로를 고치거나 중간 수치를 옮겨 적지 않고 공개 진입점 하나로 계산할 수 있도록 구성하였다.

규칙 기반 문장분류를 사용하는 이유

이 연구는 기업의 디지털 공시가 어떤 방향을 담고 있는지를 측정한다. 디지털 기술을 언급한 문장이라도 기술 소개, 외부 시장 동향, 해당 기업의 구체적 활동은 연구상 의미가 다르다. 특히 고객·서비스·채널·거래·수익과 연결된 공시를 구분해야 비즈니스 모델 지향 디지털 공시(BMODD)와 후속 경영효율의 관계를 분석할 수 있다.

Python 분류는 이러한 개념 구분을 현재 잠금자료의 25,041,971 개 문장 단위에 같은 절차로 적용하기 위한 구현이다. 문장 내용과 함께 기업명·보고연도에 관한 조건을 적용하고, 판정 결과를 기업연도별 공시비율로 집계한다. 연구자는 각 공시변수가 어떤 원문과 규칙에서 산출되었는지 확인하면서 기업과 연도에 걸친 분석을 수행할 수 있다.

판정에서는 디지털 관련성(C), 기업 활동의 구체성과 실질성(S), 사업모델 연결(B)을 구분해 기록한다. NonBMODD 는 실질적 디지털 문장 중 BMODD 규칙에 해당하지 않는 잔여범주다. 이 구분은 디지털 공시의 총량과 그 안에서 사업모델을 지향하는 공시를 나누어 살펴보기 위한 것으로, NonBMODD 전체를 내부 시스템이나 기술 인프라 활동으로 해석하지 않는다.

규칙 기반 방법에서는 독자가 어휘, 문맥 조건, 제외 규칙과 적용 순서를 직접 검토할 수 있다. 공개된 코드와 기준을 대조하여 개별 문장의 판정과 기업연도 지표의 산출 과정을 확인할 수 있다는 점이 이 설계의 중요한 이유다. Python 은 이 절차를 일관되게 실행하는 도구이며, 코드북의 개념적 판단은 어휘와 정규표현식으로 근사한다. 따라서 실행의 재현성과 인간 코딩에 대한 분류 성능은 구분해 평가한다.

1 재현 범위와 검증 결과

2015~2025 년 KOSPI·KOSDAQ 비금융 상장기업의 22,654 개 기업연도와 2,402 개 기업을 대상으로 한다. 동일한 잠금 원문과 재무 입력을 사용하여 원문 추출부터 문장분류, 기업연도 지표 생성, 보존된 본문·추가분석 모형 추정까지 세 차례 새로 실행하였다. 매회 25,041,971 개 문장 단위를 실제 판정했으며 예측 체크포인트를 재사용하지 않았다.

검증 대상	세 차례의 실제 확인 결과
보고서별 결과	매회 22,654 개 식별자와 문장 수, 범주별 집계, 추출 텍스트·분류 해시 일치
기업연도 및 회귀	기업연도 지표와 분석표본 일치; 매회 96 개 지정 필드 및 9 개 비교군 확인; 21 개 수치·그림 파일의 세 실행 간 바이트 일치
집계	D 25,041,971 / 후보 338,468 / 실질적 디지털 49,704 / BMODD 25,070 / NonBMODD 24,634
입력 및 네트워크	기존 ZIP·저장 HTML 재사용, 새 웹·재무 다운로드 0 회, 원자료 및 분류 규칙 변경 없음

검증대상은 현재 잠금 입력판이다. 과거 25,080,866 개 문장판을 복원했다는 뜻과 구별한다. 인간 코딩의 κ 와 해당 표본을 이용한 분류기의 Accuracy·F1 은 이번 세 실행에서 다시 산출하지 않았으며, 실행 간 일치는 분류의 정답률과 별개의 결과다. 지원 환경은 아래 Windows 실행환경이며 다른 운영체제·하드웨어의 비트 단위 동일성은 별도 검증사항이다.

저장소 https://github.com/jincaiyi24/korean-digital-disclosure-reproducibility

분류기 규칙 버전 korean_contextual_v4_final_action_attribution_2026-08-15

2 파일과 실행환경 준비

Python 공식 배포판 3.13.12 의 Windows 64 비트 일반 빌드와 격리 가상환경을 사용한다. 3.13 계열이라는 이유로 다른 패치 버전을 대체하지 않는다. 공식 설치 파일은 https://www.python.org/downloads/release/python-31312/ 에서 확인한다. 첫 명령의 출력이 정확히 Python 3.13.12 인지 확인하고, 다른 버전이면 해당 설치본의 실행 파일 경로를 지정한다.

```
py -3.13 --version
py -3.13 -m venv .venv
$reproPy = ".\.venv\Scripts\python.exe"
& $reproPy -m pip install --require-hashes `
  -r requirements_windows_cp313_hashed.txt
& $reproPy -m pip check
```

의존성 34 개는 버전과 공식 wheel SHA-256 을 함께 잠갔다. 입력 점검은 실제 Python DLL 과 설치 패키지 payload 도 확인한다. 임의의 lxml 교체, 소스 빌드 대체, 자동 최신 버전 설치로 검사를 통과시키지 않는다. 짧은 작업경로를 권장하며 모든 결과 폴더는 매 실행마다 새 이름을 사용한다.

```
repository\
  code\
  bundle\finance\
  rules\
locked_data\
  raw_dart\
  supplemental_raw\
  viewer_capture\
```

입력	확보 위치와 역할
원문 ZIP	bundle/SOURCE_PLAN.json 에 지정된 원문 파일과 해시. ZIP 경로를 사용하는 22,639 개 보고서 기록
저장 웹 원문	15 개 보고서의 순서가 고정된 249 개 HTTP 본문. 공개 descriptor 와 요청 식별자·본문 해시를 사용
재무·시장 입력	bundle/finance/expanded_panel.csv 및 frozen_augmented_panel.csv. 고정된 분석 입력 스냅샷
규칙과 기준 결과	bundle/method 의 원본 규칙·추정 함수, rules 의 규칙 목록, 실행환경 계약 및 사후 비교용 기준 파일

재무 스냅샷은 분석 시점의 입력표를 보존한 파일이다. 원본은 그대로 두고 공개용 사본에서 자격증명이 포함될 수 있는 오류 메모와 로컬 캐시 경로만 비웠다. 나머지 원래 셀 문자열은 유지하였다. 회귀에 쓰는 공시변수와 보고서 길이는 매회 새로 계산한 D, S, B 에서 다시 생성한다. 금융자료 제공기관의 이용조건은 DATA_NOTICE.md 를 따른다. 코드의 MIT 라이선스를 외부 자료 전체의 무제한 재배포 허가로 해석하지 않는다.

3 원문 확보와 입력 점검

이 검증에서는 기존 원문을 다시 다운로드하지 않았다. 이미 원문이 있으면 위 세 입력 폴더를 지정하여 다음 점검부터 시작한다. 폴더가 서로 다른 위치에 있으면 public_run.py 의 --raw-dir, --supplemental-raw-dir, --viewer-capture-root 인자로 각각 전달할 수 있다.

```
& $reproPy -B code\public_run.py `
  --data-root ..\locked_data `
  --output ..\preflight_01
```

원문이 없는 사용자는 별도 확보 도구를 사용할 수 있다. 도구는 명세에 정해진 접수번호와 웹 요청만 사용하고 파일 해시를 검증한다. API 키는 현재 터미널의 환경변수로만 전달한다. 아래 -MaskInput 명령은 PowerShell 7 환경용이다.

```
$env:DART_API_KEY = Read-Host "OpenDART API key" -MaskInput
& $reproPy -B code\acquire_locked_reports.py `
  --bundle .\bundle --data-root ..\locked_data --fetch
[Environment]::SetEnvironmentVariable(
  "DART_API_KEY", $null, "Process")
```

이미 검증된 파일은 보존하고 누락된 파일만 확보한다. 모든 원문 검증이 끝나면 필요한 세 표준 디렉터리도 자동으로 준비한다. 이 보조 도구는 합성 HTTP 와 실제 명세를 이용한 독립 테스트를 통과했으며, 이번 세 차례 검증에서 새 원문 다운로드를 실행한 것은 아니다. 향후 사이트 응답·개정본·접근한도 때문에 잠금 바이트를 확보하지 못하면 중단한다. 그런 응답을 다른 보고서로 대체하거나 수치를 맞추는 방식으로 진행하지 않는다.

4 텍스트 추출과 문장 단위 구성

추출 경로도 측정방법의 일부다. ZIP 과 저장 웹 원문에 대응하는 명세상의 추출 절차를 적용한다. 어느 파서의 집계가 기준 숫자에 가까운지를 보고 선택하지 않는다. 원문 해시, 추출 텍스트 해시, 정렬된 문장·분류 해시는 서로 다른 단계의 검사값으로 보존한다.

문자 정규화 후 원시 행을 정제하고 한국어 종결형 또는 누적 길이 350 자에서 버퍼를 비운다. 문장부호 뒤 공백을 기준으로 나눈 조각에 최종 적격성 검사를 적용한다. 최종 조각은 길이 25~700 자, 한글 음절 15 개 이상, 코드의 토큰 정규식으로 센 토큰 5 개 이상이어야 하며 표·주소·숫자열 등 잡음 규칙을 통과해야 한다. 원시 행의 디지털 핵심어 예외와 최종 조각의 잡음 검사는 구분한다.

동일 보고서 안에서 소문자화하고 공백을 제거한 키가 같은 문장은 한 번만 센다. 다른 기업·연도까지 전역 중복제거하지 않는다. 이 절차를 통과한 모든 조각을 판정하며 디지털 후보 플래그가 1 인 문장만 분류기로 보내는 구조가 아니다.

구현 위치는 korea_digital_strategy_korean_pipeline.py 의 normalize_text, is_table_noise, is_korean_narrative_segment, split_korean_sentences 와 kosdaq_text_pipeline.py 의 score_one 이다. rules/REGEX_AND_KEYWORD_INDEX.csv 와 함수 목록에 정확한 상대경로, 원본 행 번호 및 SHA-256 이 연결되어 있다.

5 규칙 판정과 범주 우선순위

인적 코딩 기준은 기업 자체의 활동과 구체성, 고객·서비스·채널·거래·수익 연결을 개념적으로 판단한다. Python 구현은 그 기준을 어휘와 정규표현식의 조합으로 근사한다. 기업명·주체 표현, 실행 동사, 시점, 외부기업 문맥을 검사하지만 실제 행위자의 의미를 완전히 식별하거나 공시의 실행 사실을 외부 증거로 확인하는 기능은 없다. 구체적 계획도 코드에 정의된 조건의 결합으로만 인정한다.

순서	실제 구현
v2 관련성	구체 디지털 기술·온라인·자동화·데이터 운영·디지털 플랫폼·특정 소프트웨어 규칙으로 관련성을 판정; 회계·명칭충돌·부정 등 강제 제외 조건 적용
v2 실질성	기술 관련성, 행동과 귀속 조건을 결합하고 과거 연혁·범위 나열·장비 목록·외부기업·정관 목적·막연한 주장 등을 검사
구체 계획	specific_plan 의 모든 결합조건과 비과거 조건을 만족하면 S 를 회복. 이 분기 자체가 후보 C 를 별도로 회복하는 것은 아님
BMODD	S=1 안에서 직접 사업모델 규칙, 사업모델+고객·수익 결합, 스마트제품, 디지털 플랫폼+가치연결 중 하나를 충족
후속 C 처리	v2 후반의 사업목적·4 차산업혁명 관련 후보 처리 순서를 유지. 후보 여부와 최종 실질 범주는 별개

순서	실제 구현
v4 최종 제외	시장전망 • 외부주체 • 정적 범위 • 분절 목록 • 비디지털 플랫폼 • 실행 단서 부재 • 모호한 전략 • 수요 노출 • 거래상대 문맥 • 과거 사업 • 회계 나열 • 과거 연혁의 최종 veto

v4 의 최종 veto 는 S 와 B 를 0 으로 만들며 뒤에서 다시 승격하지 않는다. 비디지털 플랫폼 규칙은 C 도 0 으로 만든다. v2 의 48 개 컴파일 정규식은 IGNORECASE 를 사용하고 v4 의 16 개 컴파일 정규식은 대소문자를 구별한다. 대소문자 설정이나 규칙 순서를 일괄 통일하지 않는다.

최종 표시는 B=1 이면 BMODD, S=1 이고 B=0 이면 NonBMODD, S=0 이면 Exclude 이다. NonBMODD 는 실질적 디지털 문장 중 BMODD 규칙에 해당하지 않는 잔여범주이며 별도 내부 디지털화 분류기의 결과가 아니다. 후보 C 는 별도 플래그이고 Exclude 에는 비후보 문장도 포함된다.

전체 목록은 rules/에 분리하였다. ACTUALLY_LOADED_RULE_DECLARATIONS.json 은 실제 적재된 73 개 상수 • 규칙값을, EFFECTIVE_FUNCTIONS_AND_ORDERED_CONDITIONS.json 은 함수와 분기 순서를, INLINE_REGEX_CALLS.json 은 인라인 정규식 호출을 담는다. DECISION_PRIORITY_AND_MEASUREMENT_BOUNDARIES.json 과 SOURCE_FILE_HASH_INDEX.json 으로 판정 순서와 출처를 확인한다. 원본 파일에 남아 있으나 실제 적재되지 않는 함수는 SOURCE_FUNCTIONS_NOT_LOADED.json 으로 구분하였다. 사람이 읽는 이 요약이 실행 코드나 전체 규칙 목록을 대체하지 않는다.

6 기업연도 지표와 회귀모형

D 는 적격 • 보고서 내 중복제거 후 문장 수, C 는 디지털 후보 수, S 는 실질적 디지털 문장 수, B 는 BMODD 문장 수다. 기업코드는 8 자리, 접수번호는 14 자리 문자열로 유지하여 선행 0 을 보존한다. 결합은 기업 • 회계연도 식별자로 수행하며 t+h 는 정확히 h 년 뒤의 값에 연결한다. 중간 연도가 빠졌다고 다음 관측행을 대신 쓰지 않는다.

```
NonBMODD = S - B
BMODD_raw = B / D
NonBMODD_raw = (S - B) / D
TotalDigital_raw = S / D
z = (raw - mean(raw)) / std(raw, ddof=1)
```

주요 공시변수의 z 값은 모형별 결측 제거 전에 22,654 개 기초 기업연도에서 표본 표준편차(ddof=1)로 계산한다. D 가 양수가 아니면 원비율은 결측으로 둔다. 구성비 B/S 의 S=0 처리, 양의 B 하위표본 강도의 표준화, 각 모형의 분석표본은 해당 원함수대로 유지한다. TotalDigital 과 DigitalDisclosure 는 이름만 보고 일괄 합치지 않고 코드의 원비율 • 표준화 • 표본 규약을 따른다.

원본 소스의 BMI 계열 내부 필드명은 검증한 소스 바이트를 보존하기 위해 남겼다. 공개 표시명은 BMODD 와 NonBMODD 이며 명시적 스키마 대응으로 연결한다. 숫자 • 라벨을 바꾸는 전역 문자열 치환을 하지 않는다.

분석	유지한 실행 범위
H1 및 H2	주회귀의 모든 통제계수, 두 공시변수의 공동모형, 공분산을 이용한 계수차 검정 및 확인적 두 검정 BH 집합
H3	시점별 −2~+5, 여섯 시점 공통표본 −2~+3, 공식 공동 추정과 t+2−t 차이; 보조 비교의 원래 조정 규약
강건성	산업×연도·시장×연도 FE, 대체 노출, 양의 표본, 엄격 공통표본·확장 통제, 변화모형, 기업별 추세, 미래 공시 위약 및 IPW
추가분석	COVID-19, K-IFRS 1116, 매출·자산·회전율 로그 변화와 원래 19 개 보충검정의 BH 조정

시점별 가용표본 모형은 t 에서 현재 자산회전율 통제를 제외하고 다른 시점에서는 주 통제집합을 사용한다. 공통표본의 공식 H3 비교에는 모든 시점에 동일한 12 개 비결과형 통제를 적용한다. 기업·연도 고정효과, 단일 관측치 집단의 반복 제외, 기업 군집 공분산과 해당 자유도의 t 검정은 원함수를 따른다. 표 9 에서 제외한 세 대체모형 표시행 때문에 BH 집합을 19 개에서 줄이지 않는다. 자본시장 추가분석과 BERT 는 이 실행·배포 범위에 포함하지 않았다.

7 한 번의 진입점으로 실행하고 결과 확인하기

입력 점검과 실제 실행에는 서로 다른 새 출력 폴더를 사용한다. 아래 명령 하나가 세 개의 새 실행 디렉터리와 프로세스 풀을 만들고 원문 추출·분류·집계·모든 보존 모형 추정을 순서대로 수행한다. --rounds 1 은 한 차례 실행용이다. 실행 중 중간 코드나 입력을 바꾸지 않는다.

```
& $reproPy -B code\public_run.py `
  --data-root ..\locked_data `
  --output ..\replay_3rounds_01 `
  --run --rounds 3
```

실행 산출물	확인할 내용
classification	fresh_report_predictions.jsonl 의 보고서별 집계값·해시, PREDICTION_SEAL.json 의 실제 호출 수·체크포인트 재사용 여부
POSTHOC_CURRENT_MEASUREMENT_CHECK	예측을 봉인한 뒤에만 기준 문장 수·추출·분류 해시와 비교한 결과
empirical	BMODD_FIRM_YEAR_CLASSIFICATION.csv, 각 모형의 계수·표본키, MODEL_OUTPUTS_SEAL.json 및 사후 모형 비교
전체 실행 영수증	각 FULL_CURRENT_METHOD_RUN_RECEIPT.json 과 최상위 runs/THREE_ROUND_RECEIPT.json
공개 검증 및 표시용 결과	evidence/PUBLIC_VALIDATION_SUMMARY.json, results/의 18 개 CSV 와 별칭·해시 대응 장부

이 배포에서 각 실행의 시각·PID·완료 순서를 포함한 로그 전체 바이트까지 같다고 요구하지는 않는다. 비교 대상은 고정 식별자별 문장 수·분류와 측정 해시, 기업연도 지표, 표본 및 수치 결과다. 전체 2,504만 문장의 개별 플래그 표를 저장했다고 주장하지 않으며 원함수가 흐름 중 계산한 보고서별 canonical digest를 검증한다.

공개 results/는 표시명을 BMODD로 통일한 18개 CSV다. 원 실행 파일의 숫자 문자열과 행·열 순서는 보존하고 허용된 식별자만 대응시켰다. 별칭과 CSV 직렬화 때문에 원 실행 SHA와 공개 사본 SHA가 다를 수 있으므로 PUBLIC_RESULTS_EXPORT_RECEIPT.json의 대응을 확인한다. 전체 정밀도 값은 CSV에 남기고 논문 표시는 적정 자리수로 반올림한다.

점검이 중단되면 먼저 원문·규칙·실행환경 해시와 보고서 식별자를 확인한다. 흔한 원인은 다른 접수본, HTML/XML 추출 경로, 줄바꿈에 따른 문장 경계, 패키지 빌드, 선행 0 소실 또는 분석표본 차이다. 같은 잠금 입력에 대한 중단은 차이 증거와 함께 보존한다. 기준 계수에 맞추어 원문·규칙·사람의 라벨·기준 숫자를 고치는 절차는 없다.

다른 연구자료에 규칙을 적용할 때는 frozen_api.FrozenClassifier.classify(sentence, year, corp_name)와 전체 규칙 출처를 확인한다. 입력 문장, 보고연도와 기업명도 판정에 관여한다. 논문 재현 모드는 이 배포판의 잠금 입력에 대한 실행이며 새 자료의 측정은 별도 자료판으로 기록한다.